

Лабораторная работа №6: Применение техники Transfer Learning и оценка метрик

Вариант 1: Для классификации изображений

Задача: Используя предварительно натреннированную сверточную нейронную сеть (например, ResNet, VGG, MobileNet и т.д.), создать классификатор для одного из наборов данных.

Датасеты:

1. **MNIST:** Простой классический датасет с рукописными цифрами, отлично подходит для начального знакомства с задачей классификации.
 2. **SVHN (Street View House Numbers):** Набор цифр с реальных фотографий домов, чуть сложнее MNIST, добавляет реализм и вариативность.
 3. **Fashion-MNIST:** По структуре похож на MNIST, но содержит одежду и аксессуары, повышает сложность относительно простой задачи цифр.
 4. **STL-10:** Аналогичен CIFAR-10, но изображения большего размера (96×96), что позволяет исследовать влияние разрешения на качество результата.
 5. **Oxford Flowers 102:** Специальный датасет для классификации цветов, полезен для изучения тонкостей предметной специализации моделей.
 6. **Stanford Dogs Dataset:** Контрольная задача классификации пород собак, часто используется для демонстрации возможностей моделей глубоких сетей.
 7. **Food-101:** Огромный датасет изображений еды, предназначен для проверки способности моделей различать разные виды пищи.
 8. **Aircrafts Dataset (FGVC-Aircraft):** Тяжелая задача классификации видов самолетов, демонстрирует способность сетевых моделей выявлять тонкие различия между схожими объектами.
-

Вариант 2: для детекции объектов (Object Detection)

Задача: Используйте технику трансферного обучения (Transfer Learning) для реализации детектора объектов на изображениях.

Датасеты:

1. **Pascal VOC:** Классический набор данных для детекции и сегментации, включающий около 20 категорий объектов.
2. **COCO (Common Objects in Context):** Широко используемый датасет с большим количеством аннотаций и сложной композицией сцен.
3. **Open Images Dataset:** Содержит миллионы аннотированных изображений с множеством объектов разного типа.
4. **ImageNet Object Localization Challenge:** Подходит для продвинутых проектов, требует наличия GPU и значительных вычислительных ресурсов.

5. **KITTI dataset:** Специализированный датасет для автомобильных приложений, включает большое количество транспортных средств и пешеходов.

Архитектуры:

- Faster R-CNN (Region-Based Convolutional Neural Network)
 - SSD (Single Shot MultiBox Detector)
 - RetinaNet
 - YOLO (You Only Look Once)
 - DETR (Detection Transformer)
 - и т.д.
-

Вариант 3: для семантической сегментации (Semantic Segmentation)

Задача: Реализация алгоритма сегментации изображений путем переноса весов с заранее обученной CNN (например, ResNet) на новую задачу сегментации.

Датасеты:

1. **Cityscapes:** Идеален для изучения городской среды, содержит изображения дорог, зданий, автомобилей и пешеходов.
2. **ADE20k:** Включает широкий спектр объектов и пространственных областей.
3. **CamVid:** Городские сцены Великобритании, подходящий для анализа дорожных условий.
4. **Mapillary Vistas:** Данных больше всего в сегменте дорожной инфраструктуры и городского окружения.
5. **VOC Segmentation Task:** Относится к Pascal VOC, но фокусируется именно на сегментировании изображений.
6. **BDD100K:** Калифорнийская дорожная сцена с объектами разметки и автомобилями.
7. **GTSRB (German Traffic Sign Recognition Benchmark):** Подходит для распознавания знаков дорожного движения.
8. **LIP (Look Into Person):** Для сегментации частей тела человека.
9. **Berkeley DeepDrive Semantic Segmentation Dataset:** Полезен для исследований, связанных с автономными транспортными средствами.
10. **MSRA-B (Microsoft Research Asia Building Database):** Отличается высоким качеством детализации строений.

Архитектуры:

- U-Net
- FCN (Fully Convolutional Networks)

- SegNet
- DeepLab (DeepLab v3+)
- PSPNet (Pyramid Scene Parsing Network)
- HRNet (High Resolution Net)
- Mask R-CNN (Mask Region Based CNN)
- TransUNet (Transformer UNet)

Примечание: в любом варианте можно использовать свой датасет.