

Лабораторная работа №7. Работа с трансформерной архитектурой

Вариант 1: Fine-tuning модели трансформера на задаче классификации текстов

Цель работы:

Получить практические навыки fine-tuning предварительно обученной трансформерской модели на задаче бинарной классификации текстов.

Ход работы:

1. Загрузите датасет обзоров фильмов IMDB (позитивные / негативные отзывы) или другой открытый датасет.
 2. Проведите предобработку данных: токенизацию, конверсию в числовой вид.
 3. Выберите одну из готовых моделей семейства transformer (например, RoBERTa или DistilBERT).
 4. Файнтюните выбранную модель на ваших данных.
 5. Оцените точность классификатора на контрольном множестве, постройте кривые precision-recall и ROC-AUC.
-

Вариант 2: Применение трансформеров для анализа эмоциональной окраски текста

Цель работы:

Научиться применять трансформеры для решения задачи sentiment analysis (определения эмоциональной окрашенности текста).

Ход работы:

1. Создайте собственный небольшой датасет с примерами положительных и отрицательных отзывов пользователей или используйте открытый датасет.
 2. Используя предварительно обученную модель типа BERT или XLNet, выполните трансферное обучение на вашем датасете.
 3. Предложите методы повышения производительности путем настройки гиперпараметров (learning rate, dropout, размер батча).
 4. Проверьте качество вашего классификатора на новых текстовых примерах.
-

Вариант 3: Создание чат-бота на основе архитектуры трансформеров

Цель работы:

Разработать простой диалоговый агент на основе трансформеров, способный поддерживать разговор на общие темы.

Ход работы:

1. Подготовьте небольшую базу диалогов на русском языке, содержащую приветствия, прощания, запросы на информацию общего характера или используйте открытый датасет.
 2. Обучите генератор диалогов на основе модели типа GPT-2 или T5.
 3. Разработайте интерфейс взаимодействия с ботом (например, командную строку или веб-интерфейс).
 4. Протестируйте возможности бота, выявив слабые стороны и направления улучшения.
-

Вариант 4: Генерация текста с ограничениями с помощью T5

Цель работы:

Применение моделей типа T5 для контролируемого генеративного моделирования текста.

Ход работы:

1. Использовать открытый датасет Habr Articles Dataset /OpenSubtitles или другой открытый датасет для подготовки корпуса текстов.
 2. Поставьте задачу пересказа текста или сокращения статей.
 3. Дообучить модель T5 с задачей контролируемой генерации (указывая длину выходного текста, ключевые слова и т.п.).
 4. Проверьте, насколько точно модель сохраняет смысл исходного текста и соблюдает ограничения на генерацию.
-

Вариант 5: Использование RoBERTa для автоматической маркировки текста

Цель работы:

Применить модель RoBERTa для решения задачи маркировки имен собственных (Named Entity Recognition, NER).

Ход работы:

1. Возьмите датасет FLORECE / CoNLL-RusEval-2011 или другой открытый датасет для выделения имен собственных (персонажи, организации, места и т.д.) в тексте.
 2. Превратите задачу NER в задачу классификации каждой токенизированной единицы текста.
 3. Обучите модель RoBERTa на размеченных данных и примените ее для автоматического распознавания сущностей.
 4. Определите показатели качества (precision, recall, f1-score) и проведите сравнение с существующими baseline-решениями.
-

Вариант 6: Fine-Tune GPT-2 или RuGPT для генерации креативного контента

Цель работы:

Научиться дообучению языковой модели GPT-2 или RuGPT для создания творческого контента (рассказы, стихотворения, описания товаров).

Ход работы:

1. Используйте существующий датасет художественных произведений (например, **WikiText-103** (художественный корпус)).
2. Задайте специфичные правила формирования генерируемого текста (например, ограничение количества символов, заданная тема или жанр).
3. Поэкспериментируйте с настройками temperature и top-k sampling для управления разнообразием и качеством генераций.
4. Оцените полученные тексты с точки зрения оригинальности, связности и соответствия поставленным условиям.

Полезные ресурсы: для поиска датасетов Kaggle.com и <https://huggingface.co>.

<https://huggingface.co/learn/llm-course/ru/> про трансформеры и fine-tuning, включая практику.

<https://education.yandex.ru/handbook/ml/article/transformery> теория про трансформеры.